

## Introduktion till rekursion

# Algoritmer

**Definition:** En *algorithm* är en sekvens av väldefinierade instruktioner som löser ett problem eller utför en beräkning med ett ändligt antal steg.

## Beståndsdelar:

- *sekvens* (en följd av instruktioner)
- *selektion* (**if**, **elif**, **else**)
- *iteration* (**for**, **while**)
- *abstraktion* (funktioner, metoder)

# Exempel: Fakultetberäkning

Fakulteten kan definieras *iterativt*:

$$n! = \begin{cases} 1 & \text{om } n = 0 \\ 1 \cdot 2 \cdot 3 \cdot \dots \cdot n & \text{om } n > 0 \end{cases}$$

vilket kan uttryckas i kod med någon form av loop:

```
def fac(n):  
    result = 1  
    for i in range(1, n+1):  
        result *= i  
    return result
```

# Rekursiv fakultetsberäkning

Fakulteten kan också definieras *rekursivt*:

$$n! = \begin{cases} 1 & \text{om } n = 0 \\ n \cdot (n - 1)! & \text{om } n > 0 \end{cases}$$


```
def fac(n):  
    if n == 0:  
        return 1  
    else:  
        return n*fac(n-1)
```

```
def fac(n):  
    result = 1  
    if n > 0:  
        result = n*fac(n-1)  
    return result
```



UPPSALA  
UNIVERSITET

# Demonstration med hjälp av debuggern i Thonny



# Exempel: Beräkna $x^n$

Operationen  $x^n$  där  $x$  reellt och  $n$  heltal:

Iterativt: 
$$x^n = \begin{cases} 1 & \text{om } n = 0 \\ x \cdot x \cdot x \cdot \dots \cdot x & \text{om } n > 0 \end{cases}$$

Rekursivt: 
$$x^n = \begin{cases} 1 & \text{om } n = 0 \\ x \cdot x^{n-1} & \text{om } n > 0 \end{cases}$$

# Om n får vara negativt?

$$x^n = \begin{cases} \frac{1}{x^{-n}} & \text{om } n < 0 \\ 1 & \text{om } n = 0 \\ x \cdot x^{n-1} & \text{om } n > 0 \end{cases}$$

```
def power(x, n):  
    if n < 0:  
        return 1./power(x, -n)  
    elif n == 0:  
        return 1  
    else:  
        return x*power(x, n-1)
```

# Varför rekursion?

- Kraftfullt sätt att *hitta* algoritmer.
- Ett kraftfullt sätt att hitta *effektiva* algoritmer.
- *Naturligt* i många problem.

Men också

- Kraftfullt sätt att konstruera ineffektiva algoritmer



# Rekursion generellt

1. Dela upp problemet i ett eller flera delproblem av samma typ.
2. Lös delproblemen (rekursivt)
3. Kombinerar lösningarna till delproblemen till en lösning av ursprungsproblemet.

Det måste finnas minst ett rekursionsterminerande fall, så kallade basfall.

Fakultetsberäkningen  $n!$ :

- **Ett** delproblem: Beräknas  $(n - 1)!$ .
- **Kombinera**: Multiplicera med  $n$ .
- **Basfall**:  $n = 0$ .

# Hur hittar man delproblemen?

I ovanstående exempel definieras problemstorleken av ett tal  $n$  som ges som parameter:  $n!$  och  $x^n$ .

Annat exempel:

`number_of_digits(x)`

som ska returnera antalet decimala siffror i heltalet  $x$ :

`number_of_digits(125) → 3`

`number_of_digits(2341562) → 7`

```
def number_of_digits(x):  
    if x < 10:  
        return 1  
    else:  
        return 1 + number_of_digits(x//10)
```

# Ibland kan delproblemen göras på olika sätt

Skriv funktionen `reverse(lst)` som returnerar en ny lista där elementen i listan `lst` kommer i omvänd ordning.

(Vi ignorerar alla inbyggda funktioner och metoder för att reversera.)

```
def reverse(lst):  
    if len(lst) <= 1:  
        return lst  
    else:  
        mid = len(lst)//2  
        return reverse(lst[mid:]) + reverse(lst[:mid])
```

**Fråga:** Hur gör vi samma operation på en sträng?

# Ibland är rekursionen självklar

Antag att vi har följande *iterativa* funktion:

```
def reverse_list(lst):  
    result = []  
    for x in lst:  
        result.insert(0, x)  
    return result
```

In: [1, [2, [3, 4]], [[5, 6], 7], [8, 9]]

Ut: [[8, 9], [[5, 6], 7], [2, [3, 4]], 1]

# Ibland är rekursionen självklar ...

Antag nu att funktionen även ska vända på alla ingående dellistor dvs

In: [1, [2, [3, 4]], [[5, 6], 7], [8, 9]]

Ut: [[9, 8], [7, [6, 5]], [[4, 3], 2], 1]

Enkelt! Vi har ju en funktion som reverserar listor:

```
def reverse_list(lst):  
    result = []  
    for x in lst:  
        result.insert(0, x)  
    return result
```

```
def reverse_list(lst):  
    result = []  
    for x in lst:  
        if type(x) is list:  
            x = reverse_list(x)  
        result.insert(0, x)  
    return result
```

# Exempel med två basfall

En funktion som tar emot två listor med tal och returnerar en ny lista där elementen består av talen talen summerade parvis:

```
summa([1,2,3], [1,2,3,4,5]) → [2,4,6,4,5]  
summa([1,2,3], [5,7])      → [5,9,3]
```

```
def summa(x, y):  
    if len(x) == 0:  
        return y  
    elif len(y) == 0:  
        return x  
    else:  
        return [x[0] + y[0]] + summa(x[1:], y[1:])
```




UPPSALA  
UNIVERSITET

*The end*




## Rekursion: Två exempel.





# Hanois torn



En trave brickor av olika storlek som ska flyttas från stället **A** till stället **C** med iakttagande av följande regler:

- Bara en bricka får flyttas i taget
- Man får aldrig lägga en större bricka på en mindre


För att detta ska vara möjligt behövs en "hjälpplats" **B**



UPPSALA  
UNIVERSITET

# Visualisering


## Tom flyttar brickor



# Tháp Hà Nội

Beteckna problemet att flytta  $n$  brickor från ett ställe till ett annat med  $h(n)$ .


Vi vill alltså lösa problemet:



# Hanois torn

För att kunna flytta den understa brickan från A till C måste alla andra brickor ligga på B.


Vi måste alltså börja med att lösa problemet att flytta  $n-1$  brickor från A till B:




1. Flytta  $n-1$  brickor från A till B med hjälp av C



# Hanois torn




# Hanois torn



2. Flytta 1 bricka från  $A$  till  $C$ .

# Hanois torn



3. Flytta  $n - 1$  brickor från  $B$  till  $C$  med hjälp av  $A$

# Hanois torn

## Algoritm:

1. Flytta  $n - 1$  brickor från  $A$  till  $B$  med hjälp av  $C$ .
2. Flytta 1 bricka från  $A$  till  $C$ .
3. Flytta  $n - 1$  brickor från  $B$  till  $C$  med hjälp av  $A$ .

Observera att det är två rekursiva anrop samt att uppgifterna om från, till och med hjälp av varierar. Platserna  $A$ ,  $B$  och  $C$  har byter alltså roller.

**Tips 1:** Enklast kod får man om man använder 0 som basfall.


**Tips 2:** Det räcker med 5 rader kod inklusive **def**, **if** och **else** för att lösa uppgiften!





UPPSALA  
UNIVERSITET

# Växlingsproblemet



# Växlingsproblemet

Antag att vi har mynt/sedlar med följande värden: 1, 5, 10, 50, 100.  
På hur många olika sätt kan vi växla ett givet belopp?

Exempel: Beloppet 12 kan växlas på 4 olika sätt:

$1 \times 10 + 2 \times 1$ ,  $2 \times 5 + 2 \times 1$ ,  $1 \times 5 + 7 \times 1$  och  $12 \times 1$

Vi vill skriva en funktion


`exchange(a, coins)`

som returnerar antalet sätt som man kan växla beloppet `a` med de valörer som finns i `coins`.

Anropet `exchange(12, [1, 5, 10, 50, 100])` ska alltså returnera 4.

# Växlingsproblemet

Mängden möjliga växlingar:



# Växlingsproblemet

Det ger följande kod:

```
def exchange(a, coins):  
    return \  
        exchange(a, coins[1:]) + \  
        exchange(a-coins[0], coins)
```

Basfall?

- $a = 0$                       Lyckad. Räkna 1
- $a < 0$                         Misslyckad. Räkna 0
- coins tom                      Misslyckad. Räkna 0

# Växlingsproblemet

Slutlig version:

```
def exchange(a, coins):  
    if a == 0:  
        return 1  
    elif a < 0 or len(coins) == 0:  
        return 0  
    else:  
        return \  
            exchange(a, coins[1:]) + \  
            exchange(a-coins[0], coins)
```

Två utmatningar (frivilliga):

1. Skriv en funktion som listar de gjorda växlingarna.
2. Lista möjliga växlingar givet ett begränsat antal av varje mynt.



UPPSALA  
UNIVERSITET

*The end*



## Introduktion till komplexitetsanalys

# Beräkna $x^n$ iterativt

$$x^n = \begin{cases} 1 & \text{om } n = 0 \\ x \cdot x \cdot x \cdot \dots \cdot x & \text{om } n > 0 \end{cases}$$

```
def power(x, n):  
    result = 1  
    for i in range(1, n+1):  
        result *= x  
    return result
```

Algoritmen gör  $n$  multiplikationer så tiden växer linjärt med  $n$  oberoende av  $x$ .

$$\frac{10}{4}$$

$$10 \cdot \frac{1}{4}$$



# Beräkna $x^n$ rekursivt

```
def power(x, n):  
    if n == 0:  
        return 1  
    else:  
        return x*power(x, n-1)
```

Om vi låter  $t(n)$  stå för tiden anropet  $\text{power}(x, n)$  tar så gäller

$$t(n) = \begin{cases} c & \text{om } n = 0 \\ d + t(n-1) & \text{om } n > 0 \end{cases}$$

$$t(n) = d + t(n-1) = d + d + t(n-2) = d + d + d + t(n-3) = \dots$$

$$\dots = d \cdot n + t(0) = d \cdot n + c$$

# Effektivare beräkning av $x^n$

Antag att vi vill beräkna  $x^{16}$ .

Om vi börjar med att beräkna  $x^8$  så räcker en kvadrering för att få  $x^{16}$

och  $x^8$  kan beräknas med att kvadrera  $x^4$

och  $x^4$  kan beräknas med att kvadrera  $x^2$

och  $x^2$  kan beräknas med en multiplikation.

Alltså,  $x^{16}$  kan beräkna med 4 multiplikationer i stället för 16.

Hur kan man formulera denna idé till en generell algoritm?

# Effektivare beräkning av $x^n$

Antag att  $n$  är jämnt och  $\geq 0$ :

$$x^n = \begin{cases} 1 & \text{om } n = 0 \\ (x^{n/2})^2 & \text{om } n > 0 \end{cases}$$

Om  $n$  är udda så är  $n-1$  jämnt:

$$x^n = \begin{cases} 1 & \text{om } n = 0 \\ (x^{n/2})^2 & \text{om } n > 0, n \text{ jämnt} \\ x \cdot (x^{(n-1)/2})^2 & \text{om } n > 0, n \text{ udda} \end{cases}$$

# Effektivare beräkning av $x^n$

```
def power(x, n):  
  
    def sqr(x):  
        return x*x  
  
    if n<0:  
        return 1./power(x, -n)  
    elif n==0:  
        return 1  
    elif n%2==0:  
        return sqr(power(x, n//2))  
    else:  
        return x*sqr(power(x, (n-1)//2))
```

$$\left\{ \begin{array}{l} 1 \\ (x^{n/2})^2 \\ x \cdot (x^{(n-1)/2})^2 \end{array} \right.$$

# Hur många multiplikationer gör denna algorithm?

Om  $n$  är en jämn 2-potens, dvs om  $n = 2^k$  ?

Krävs  $k = \log_2 n$  multiplikationer

Om  $n$  inte är en jämn 2-potens, dvs om  $n \neq 2^k$  ?

Krävs högst en extra multiplikation innan problemet halveras  
dvs högst  $2 \log_2 n$  multiplikationer.

Ungefär hur många multiplikationer krävs för att beräkna  
 $x^{1000}$  respektive  $x^{1000000}$  ?

# Sökning i en lista

Att söka efter ett värde i en Python-lista görs normalt med operatoren `in` t. ex. med uttrycket `if x in lst`

Även om vi inte ser det så måste det bakom scenen finnas kod liknande den här:

```
def search(x, lst):  
    for e in lst:  
        if e == x:  
            return True  
    return False
```

Arbetet är således, åtminstone i värsta fall, proportionellt mot listans längd.

Operatoren `in` och funktionen `search` har samma *komplexitet* även om operatoren `in` säkert är mycket snabbare.

# Effektivare sökning

Om data i listan är sorterade i storleksordning kan sökningen göras väsentligt effektivare:

*om  $x < \text{värdet i mitten}$ :*  
*sök i vänster halva*  
*annars:*  
*sök i höger halva*

Metoden som kallas binär sökning är enkel i implementera både rekursivt och iterativt.

# Komplexitet för binär sökning

Metoden halverar sökmängden för varje iteration eller rekursivt anrop.

$$n \rightarrow \frac{n}{2} \rightarrow \frac{n}{2^2} \rightarrow \frac{n}{2^3} \rightarrow \dots \rightarrow \frac{n}{2^k}$$

När är  $\frac{n}{2^k} = 1$  ?

$$n = 2^k \Leftrightarrow k = \log_2 n$$

Hur många iterationer/funktionsanrop behövs för att söka i en lista med  
 $10^6$ ,  $10^9$  och  $10^{12}$  element?



# Algoritm- eller komplexitetsanalys

Studerar hur tiden för en algoritm beror på indata.

Resultat av typen:

*tiden växer proportionellt mot kvadraten på antalet element*

eller

*tiden är konstant oberoende av input*

eller

*tiden växer exponentiellt med problemstorleken*



UPPSALA  
UNIVERSITET

*The end*



# MA1: L04

*Tom Smedsaas*

Asymptotisk notation  
Ordo ( $\mathcal{O}$ ), Omega ( $\Omega$ ) och Theta ( $\Theta$ )

# Asymptotisk notation

Exempel på formuleringar:

- *Den enkla algoritmen för att beräkna  $x^n$  är  $\Theta(n)$*
- *Kvadreringsalgoritmen för att beräkna  $x^n$  är  $\Theta(\log n)$*
- *Binärsökningsalgoritmen är  $\Theta(\log n)$*
- *Linjärsökningsalgoritmen är  $\mathcal{O}(n)$  alltid*
- *Linjärsökningsalgoritmen är  $\mathcal{O}(1)$  i bästa fall*
- *Linjärsökningsalgoritmen är  $\mathcal{O}(n)$  i genomsnitt*

# Asymptotisk notation - definition

En funktion  $t(n)$  sägs vara  $\mathcal{O}(f(n))$  om det existerar två konstanter  $c$  och  $n_0$  sådana att

$$|t(n)| < c|f(n)| \quad \text{för alla } n > n_0$$

Observera att detta är en *matematisk* definition!

# Asymptotisk notation

Påstående:  $f(n) = n^2 + 10n + 100$  är  $\mathcal{O}(n^2)$

Varför?

Om  $n > 1$  så

$$|f(n)| = n^2 + 10n + 100 < n^2 + 10n \cdot n + 100 \cdot n \cdot n = 111n^2$$

Alltså duger konstanterna  $c = 111$  och  $n_0 = 1$

Observera att det är *existensen* som är viktig – inte värdena!

# Asymptotisk notation

Eftersom  $\mathcal{O}$  är en **övre** gräns behöver det inte innebära så mycket. Funktionen på förra bilden är t.ex. automatiskt  $\mathcal{O}(n^3)$  och  $\mathcal{O}(2^n)$ .

För att ange en **undre** gräns används  $\Omega$  en liknande definition med  $>$  i stället för  $<$ .

Exempelfunktionen är alltså också  $\Omega(n^2)$ .

En funktion som är både  $\mathcal{O}(f(n))$  och  $\Omega(f(n))$  sägs vara  $\Theta(f(n))$ .

I datavetenskapen är det vanligt att säga  $\mathcal{O}$  när man menar  $\Theta$ .

# Användning i algoritmanalys

Funktionerna som vi uppskattar är *tid* eller *antal gånger* någon central operation utförs.

**Exempel:** Antal multiplikationer som utförs i kvadreringsalgoritmen för att beräkna  $x^n$  är  $\Theta(\log n)$ .

Behöver vi inte ange bas i logaritmen?

Nej, eftersom

$$\log_a x = \frac{1}{\log_b a} \cdot \log_b x$$



# Användning i algoritmanalys

## Exempel:

$O(1)$	indexering i array (Python-lista)
$\Theta(\log n)$	binär sökning, kvadreringsalgoritmen
$\Theta(n)$	<code>insert(0, x)</code> i en lista med $n$ lagrade värden
$\Theta(n \log n)$	snabba sorteringsmetoder
$\Theta(n^2)$	enkla sorteringsmetoder
$\Theta(n^3)$	multiplikation av $n \times n$ - matriser

# I algoritmanalys

När man analyserar algoritmer kan man behöva skilja på bästa, värsta och genomsnittlig komplexitet.

## Exempel:

Att sortera  $n$  element med *instickssortering* kräver

- $\Theta(n)$  operationer i bästa fall
- $\Theta(n^2)$  operationer i värsta fall
- $\Theta(n^2)$  operationer i genomsnitt

Vad menar man med "i genomsnitt"?

# I algoritmanalys

När man diskuterar sökning behöver man ofta skilja mellan "lyckad" och "misslyckad" sökning.

Till exempel, funktionen

```
def search(x, lst):  
    for e in lst:  
        if e == x:  
            return True  
    return False
```

kräver för *lyckad* sökning

- $\Theta(1)$  operationer i bästa fall
- $\Theta(n)$  operationer i genomsnitt
- $\Theta(n)$  operationer i värsta fall

medan misslyckad sökning alltid kräver  $\Theta(n)$  operationer.

# Tidsuppskattningar

Antag att vi vet att tiden för en viss algoritm är  $\Theta(f(n))$ . Då kan vi uppskatta tiden för stora värden på  $n$  med funktionen

$$t(n) = c \cdot f(n)$$

Konstanten  $c$  beror på många saker (dator, os, programmerare, ...).

För en viss implementation och dator kan den uppskattas genom att göra en eller flera tidsmätningar.

# Exempel

Antag att tiden för ett program som implementerar en  $\Theta(n \log n)$  - algoritm har uppmätts till 1 sek för en  $n = 10^3$ .

Hur lång tid kommer programmet då ta för  $n = 10^6$  ?

$$t(n) = c n \log n$$

$$t(10^3) = c \cdot 10^3 \log 10^3 = 1$$

$$c = 1/3000$$

$$t(10^6) = \frac{1}{3000} \cdot 10^6 \log 10^6 = 2000 \text{ sek} \approx 33 \text{ min}$$

# Exempel

Antag samma mätning men att det är en  $\Theta(n^2)$  - algoritm.  
Hur lång tid kommer programmet då ta för  $n = 10^6$  ?

$$t(n) = c \cdot n^2$$

$$t(10^3) = c \cdot (10^3)^2 = 1$$

$$c = 10^{-6}$$

$$t(10^6) = 10^{-6} \cdot (10^6)^2 = 10^6 \text{ sek} \approx 12 \text{ dagar}$$

Slutsats: En  $\Theta(n \log n)$  - algoritm är *mycket* snabbare än en  $\Theta(n^2)$  - algoritm för stora värden på  $n$ .



UPPSALA  
UNIVERSITET

*The end*



# Insticks- och samsortering

*Tom Smedsaas*

Två sorteringsalgoritmer:  
instickssortering och samsortering  
(mergesort)



# Sortering

Vanliga algoritmer att ta upp är

- Instickssortering
- Urvalssortering
- Bubbelsortering


Egenskaper:

- Enkla att förstå
- Enkla att programmera
- Alla  $\Theta(n^2)$  i genomsnitt

# Instickssortering


Ett vanligt sätt att beskriv instickssorteringen är att säga att listan består av två delar – en sorterad och en osorterad.

Från början innehåller den sorterade delen bara det första elementet:



För varje steg utvidgas den sorterade delen med det som står först i den osorterade delen


Så här kan det se ut vid den fjärde utvidgningen:



# Instickssortering rekursivt

För att sortera en lista med  $n$  element sorterar vi först de  $n - 1$  första elementen varefter vi infogar det sista elementet så att sorteringen behålls.

```
def ins_sort(lst, n):  
    if n <= 1:  
        return  
    ins_sort(lst, n-1)  
    i = n-1  
    while i > 0 and lst[i] < lst[i-1]:  
        lst[i-1], lst[i] = \  
            lst[i], lst[i-1]  
        i -= 1
```



# Instickssortering – bästa fall

```
def ins_sort(lst, n):  
    if n <= 1:  
        return  
    ins_sort(lst, n-1)  
    i = n-1  
    while i>0 and lst[i] < lst[i-1]:  
        lst[i-1], lst[i] = lst[i], lst[i-1]  
        i -= 1
```

Låt  $t(n)$  vara antalet gånger while-villkoret beräknas.

I *bästa* fall (om värdena redan är sorterade):

$$t(n) = t(n-1) + 1 = (t(n-2) + 1) + 1 = \dots = n$$

# Instickssortering – värsta fall

```
def ins_sort(lst, n):  
    if n <= 1:  
        return  
    ins_sort(lst, n-1)  
    i = n-1  
    while i>0 and lst[i] < lst[i-1]:  
        lst[i-1], lst[i] = lst[i], lst[i-1]  
        i -= 1
```

I ***värsta*** fall (om sorterat i omvänd ordning):

$$\begin{aligned} t(n) &= t(n-1) + n = (t(n-2) + (n-1)) + n = \dots \\ &= 1 + 2 + \dots + n = \frac{n \cdot (n+1)}{2} \end{aligned}$$

# Instickssorteringen – genomsnitt

```
def ins_sort(lst, n):  
    if n <= 1:  
        return  
    ins_sort(lst, n-1)  
    i = n-1  
    while i>0 and lst[i] < lst[i-1]:  
        lst[i-1], lst[i] = lst[i], lst[i-1]  
        i -= 1
```

I *genomsnitt* tänker vi oss att elementen reser halva vägen:

$$t(n) = t(n-1) + n/2 = (t(n-2) + (n-1)/2) + n/2 = \dots = \frac{n \cdot (n+1)}{4}$$

Således  $\Theta(n^2)$  både i genomsnitt och i värsta fall.

# Balansering av algoritmen

I stället för att infoga elementen ett och ett kan man ta flera åt gången.


8	3	4	7	2	9	1	5
---	---	---	---	---	---	---	---

Bäst blir det om man delar i mitten:

1. Dela mängden i två lika stora delar.
2. Sortera delarna var för sig.
3. Sammanfoga delarna.




# Mergesort








# Mergesort - illustration







# Mergesort-illustration







# Mergesort-illustration




*Sort separately*






# Mergesort-illustration






# Mergesort-illustration





# Mergesort-illustration



# Analys av mergesort

Vi löser ett problem av storlek  $n$  genom att lösa *två* problem av storlek  $n/2$  samt en sammanfogning av de två lösningarna.

Tiden för att sammanfoga de två lösningarna är proportionell mot  $n$ .

Låt  $t(n)$  vara tiden det tar att sortera  $n$  element. Då gäller

$$t(n) = \begin{cases} c & \text{om } n = 0 \\ 2t(n/2) + d \cdot n & \text{om } n > 0 \end{cases}$$

där  $c$  och  $d$  är obekanta konstanter.

# Analys av mergesort

Om  $n$  är en jämn 2-potens,  $n = 2^k$ , så gäller

$$\begin{aligned} t(n) &= 2t(n/2) + dn = \\ &= 2\left(2t(n/4) + \frac{dn}{2}\right) + dn = \\ &= 4t(n/4) + dn + dn = \\ &= 2^k t(n/2^k) + kdn = nt(1) + dn \log_2 n \end{aligned}$$

Således är algoritmen komplexitet  $\Theta(n \log n)$ .

Detta gäller även om  $n$  inte är en jämn tvåpotens.



# Två frågor

- Antag att det tar 1 sekund att sortera  $10^3$  tal den enkla insticksorteringen. Hur lång tid kommer det då att ta att sortera  $10^6$  tal?
- Samma fråga för mergesort.




UPPSALA  
UNIVERSITET

*The end*


# Hanois torn

*Tom Smedsaas*

Komplexitet för problemet Hanois torn



# Hanois torn




En hög med brickor ska flyttas från A till C med följande regler:

1. Endast en bricka får flyttas åt gången
2. En större bricka får aldrig läggas på en mindre.


# Hanois torn

Låt  $h(n)$  stå för problemet att flytta  $n$  brickor.






# Hanois torn






# Hanois torn






# Hanois torn







# Hanois torn



# Analys av komplexiteten

Vi löser ett problem av storleken  $n$  genom att lösa två problem av storleken  $n - 1$  och ett problem av storleken 1.

Om  $h(n)$  står för antalet brickförflyttningar blir då

$$\begin{aligned}h(n) &= 2h(n - 1) + 1 = \\&= 2(2h(n - 2) + 1) + 1 = 4h(n - 2) + 2 + 1 = \dots = \\&= 2^k h(n - k) + 2^{k-1} + 2^{k-2} + \dots + 2 + 1 = \\&= 2^{n-1} h(1) + 2^{n-2} + \dots + 2 + 1 = \\&= 2^{n-1} \cdot 1 + 2^{n-2} + \dots + 2 + 1 = 2^n - 1\end{aligned}$$

Hopplöst för stora  $n$ .



UPPSALA  
UNIVERSITET

*The end*



# Fibonacci-tal

*Tom Smedsaas*

Komplexitet vid rekursiv beräkning av  
Fibonacci-tal.

Vi ska också introducera tekniken  
“memoization” för att effektivisera vissa  
rekursiva program.

# Rekursiv Fibonacci-funktion

Fibonacci-talen kan definieras rekursivt:

$$F_n = \begin{cases} 0 & \text{om } n = 0 \\ 1 & \text{om } n = 1 \\ F_{n-1} + F_{n-2} & \text{om } n > 1 \end{cases}$$


och beräknas med en rekursiv funktion:

```
def fib(n):  
    if n == 0:  
        return 0  
    elif n == 1:  
        return 1  
    else:  
        return fib(n-1) + fib(n-2)
```



UPPSALA  
UNIVERSITET

# Demo 1



# Komplexitet för fib-funktionen

```
def fib(n):  
    if n == 0:  
        return 0  
    elif n == 1:  
        return 1  
    else:  
        return fib(n-1) + fib(n-2)
```

Låt  $t(n)$  vara antalet additioner som görs av anropet  $\text{fib}(n)$ .

$$t(n) = t(n-1) + t(n-2) + 1$$

Kan uppskattas uppåt:

$$t(n) = t(n-1) + t(n-2) + 1 < 2t(n-1) + 1 = 2^n - 1$$

Kan uppskattas nedåt:

$$t(n) = t(n-1) + t(n-2) > 2t(n-2) + 1 \approx \sqrt{2}^n$$


Man kan visa att  $t(n) \approx c \cdot 1.618^n$

Hopplöst för stora  $n$  !

# Varför blir det så ineffektivt?

```
def fib(n):  
    if n == 0:  
        return 0  
    elif n == 1:  
        return 1  
    else:  
        return fib(n-1) + fib(n-2)
```

Vad händer vid  
anropet fib(6) ?





# "Memoization"

Spara beräknade värden och använd dessa i första hand.

```
memory = {0:0, 1:1}

def fib(n):
    if n not in memory:
        memory[n] = fib(n-1) + fib(n-2)
    return memory[n]
```

Kan nu beräkna väldigt stora Fibonacci-tal!



UPPSALA  
UNIVERSITET

# Demo 2



# Kan man dölja variabeln memory?

Variabeln memory är nu global – inte så vackert!  
Den används ju bara i funktionen fib.

```
memory = {0:0, 1:1}

def fib(n):
    if n not in memory:
        memory[n] = fib(n-1) + fib(n-2)
    return memory[n]
```

Så här?

```
def fib(n):
    memory = {0:0, 1:1}
    if n not in memory:
        memory[n] = fib(n-1) + fib(n-2)
    return memory[n]
```



UPPSALA  
UNIVERSITET

# Demo 3



# Bättre försök att gömma memory


Låt fib vara en "omslagsfunktion" till den rekursiva funktionen och placera memory i den:

```
def fib(n):  
  
    memory = {0:0, 1:1}  
  
    def _fib(n):  
        if n not in memory:  
            memory[n] = _fib(n-1) + _fib(n-2)  
        return memory[n]  
  
    return _fib(n)
```



UPPSALA  
UNIVERSITET

# Demo 4



# Alltså

- Variabler skapade i en funktion är lokala i den funktionen.
- Funktionsdefinitioner kan innehålla funktionsdefinitioner. Sådana funktioner är lokala till den omslutande funktionen.
- I en lokal funktion är variablerna i den omslutande funktionen tillgängliga.
- Variabler deklarerade på högsta nivå (utanför alla funktioner) är global Undvik att använda globala variabler!

**Frivillig övning:** Skriv om funktionen exchange med memoization.



# Pythonspecialitet

```
from functools import lru_cache


@lru_cache()
def fib(n):
    if n == 0:
        return 0
    elif n == 1:
        return 1
    else:
        return fib(n-1) + fib(n-2)
```





UPPSALA  
UNIVERSITET

# Demo 5





UPPSALA  
UNIVERSITET

*The end*



# Sortering

*Tom Smedsaas*

## Experiment med några sorteringsmetoder.

Avsikten är att visa hur man kan verifiera teori  
med experiment samt att peka på när  
rekursion är bra och när den är dålig.



# Insticksortering igen

```
def ins_sort_rec(lst):  
    return _ins_sort_rec(lst, len(lst))  
  
def _ins_sort_rec(lst, n):  
    if n > 1:  
        _ins_sort_rec(lst, n-1)  
        x = lst[n-1]  
        i = n - 2  
        while i >= 0 and lst[i] > x:  
            lst[i+1] = lst[i]  
            i -= 1  
        lst[i+1] = x  
    return lst
```



# Mergesort igen

```
def merge_sort(lst):  
    if len(lst) <= 1: return lst  
    else:  
        n = len(lst)//2  
        l1 = lst[:n]  
        l2 = lst[n:]  
        l1 = merge_sort(l1)  
        l2 = merge_sort(l2)  
        return merge(l1, l2)  
  
def merge(l1, l2):  
    if len(l1) == 0:  
        return l2  
    elif len(l2) == 0:  
        return l1  
    elif l1[0] <= l2[0]:  
        return [l1[0]] + merge(l1[1:], l2)  
    else:  
        return [l2[0]] + merge(l1, l2[1:])
```

# Hur kommer tiden växa för dessa metoder?

Vi ska titta på hur tiderna förändras när storleken dubblas.

Instickssorteringen är en  $\Theta(n^2)$  – metod.

Dubblas storleken växer tiden med en faktor  $\frac{c \cdot (2n)^2}{c \cdot n^2} = 4$

Samsorteringen är en  $\Theta(n \log n)$  – metod.

Dubblas storleken växer tiden med en faktor

$$\frac{c \cdot 2n \log(2n)}{c \cdot n \log n} = 2 \cdot \frac{\log 2 + \log n}{\log n} = 2 \cdot \left(1 + \frac{1}{\log_2 n}\right)$$

Om  $n > 1000$  är faktorn mindre än 2.1.

# Testkod


```
sort_functions = [ins_sort_rec, merge_sort]

for sort in sort_functions:
    print('\n', sort.__name__)
    for n in [1000, 2000, 4000, 8000]:
        lst = []
        for i in range(n):
            lst.append(random.random())
        tstart = time.perf_counter()
        lst = sort(lst)
        tstop = time.perf_counter()
        print(f" Time for {n}\t : {tstop - tstart:4.2f}")
```



UPPSALA  
UNIVERSITET

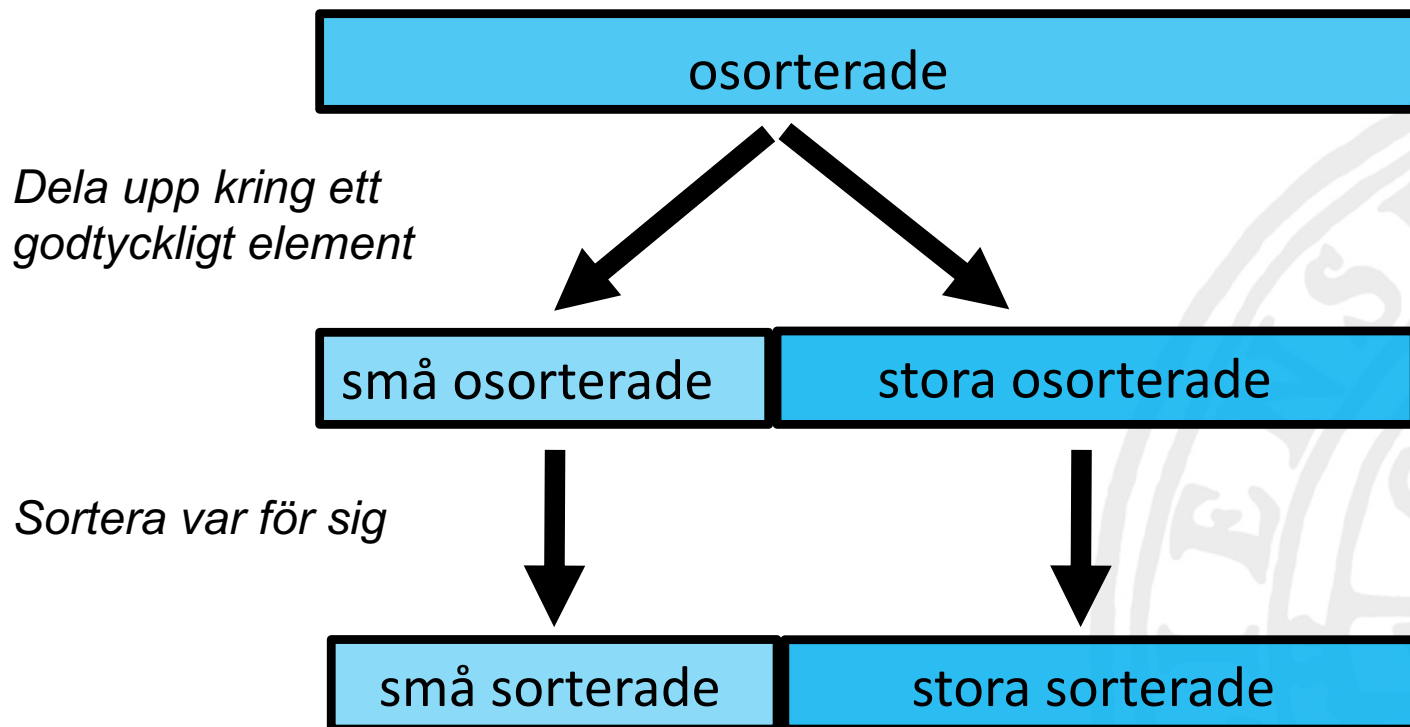
# Testkörning





# En annan sorteringsmetod

Idé: Börja med att ordna om elementen så att "små" ligger (osorterade) till vänster och "stora" ligger (osorterade) till höger.



# Partition sort

```
def psort(lst):  
    _psort(lst, 0, len(lst)-1)  
    return lst  
  
def _psort(lst, n, m):  
    if m > n:  
        ip = partition(lst, n, m)  
        _psort(lst, n, ip-1)  
        _psort(lst, ip+1, m)
```

Likheter och skillnader mot mergesort?



# Partitioneringen

```
def partition(lst, n, m):  
    if m>n:  
        p = lst[n]  
        i = n  
        j = m  
        while j > i:  
            while j>i and lst[j] > p:  
                j -= 1  
            lst[i] = lst[j]  
            while i < j and lst[i] < p:  
                i += 1  
            lst[j] = lst[i]  
            j -= 1  
        lst[i] = p  
        return i
```

Anmärkning: Metoden kallas ofta för *quicksort*.



UPPSALA  
UNIVERSITET

# Demo



# Sammanfattning

- Tidmätningar kan användas för att verifiera teoretiska resultat.
- De teoretiska resultaten för instickssortering och samsortering stämmer mycket bra i praktiken.
- $\Theta(n \log n)$  är mycket bättre än  $\Theta(n^2)$ !
- Bra att balansera algoritmerna.
- Rekursera inte över långa listor.
- Inga problem med rekursiondjupet i mergesort och quicksort.



UPPSALA  
UNIVERSITET

*The end*





UPPSALA  
UNIVERSITET

# Sammanfattning av modul MA1

# Rekursion

- Dela upp problemet i (ett eller flera) delproblem av samma slag men mindre.
- Lös delproblemen.
- Kombinera lösningarna av delproblemen till en lösning av ursprungsproblemet.

Det måste finnas ett eller flera basfall.

Det blir vanligtvis bäst kod om man använder de enklaste basfallen (t.ex. 0 i stället för 1 i Hanois torn eller en tom lista i stället för en lista med ett element).



# Varför rekursion

- Generell teknik för problemlösning.
- Lätt att hitta lösningen.
- Lätt att hitta effektiva lösningar.
- Naturligt i många sammanhang.
- Särskilt bra vid rekursivt definierade strukturer.

Men

- Lätt att producera hopplöst långsamma program.
- Problem med rekursionsdjup.

# Vad är avgörande?

Avgörande är *antalet* delproblem och *storleken* på delproblemen.

- Om vi har två eller fler delproblem med *nästan samma storlek* som ursprungsproblemet så har vi en exponentiell tillväxt.  
Exempel: Hanois torn, Fibonacci.
- Oftast bättre med *två* delproblem som har *halva storleken* är *ett* delproblem som är *nästan lika stort* som ursprungsproblemet.  
Exempel: mergesort – instickssortering
- I regel bra att *balansera* storleken på delproblemen.
- Undvik rekursion över långa strukturer – problem med stackdjupet.

# Asymptotisk notation

Ett sätt att beskriva hur tiden för en algoritm växer med problemstorleken oberoende av dator, programmeringsspråk etc.

När använder man  $\mathcal{O}$ ,  $\Theta$ , respektive  $\Omega$  ?

- $\Theta$  ger mest information.
- $\mathcal{O}$  är en *övre* gräns (ej nödvändigtvis "tät").
- $\Omega$  är en *undre* gräns.

# Ordo, Omega eller Theta?

- Om du har en "bra"  $\mathcal{O}$ -funktion kan den användas för att säga att en algoritm är bra.  
Exempel: Om du hittat på en sorteringsalgoritm är det bra att kunna säga att den är  $\mathcal{O}(n \log n)$  men meningslöst att säga att den är  $\mathcal{O}(n^2)$ .
- Om du vill säga att en algoritm är dålig kan du använda  $\Omega$ .  
Exempel: Om någon kommer med en sorteringsalgoritm kan du säga att den är inte så bra om den är  $\Omega(n^2)$  och att den är usel om den är  $\Omega(n^3)$ .  
Det är dock meningslöst att säga att den är  $\Omega(n \log n)$ .
- $\Theta$  är mest informativ. Använd om möjligt.

# Vad är bra och vad är dåligt?

- $\Theta(a^n)$  är *dåligt* om  $a > 1$ .
- $\Theta(\log n)$  är *mycket bättre* än  $\Theta(n)$ .
- $\Theta(n \log n)$  är *mycket bättre* än  $\Theta(n^2)$ .
- $\Theta(n)$  är *inte så mycket bättre* än  $\Theta(n \log n)$ .

# Tiduppskattningar

Om vi vet att en algoritm är  $\Theta(f(n))$  så kan vi uppskatta tidsåtgången  $t(n)$  för stora problem med uttrycket

$$t(n) = c \cdot f(n)$$

och uppskatta konstanten genom att mäta tiden för något  $n$ .

Man bör verifiera modellen genom att mäta tiden för några olika  $n$ .

Använd inte för små  $n$  – det blir säkrare uppskattningar ju större värden man mäter för.

# Exempel

För att verifiera komplexiteten för en viss algoritm är det bra att ha strategi för hur  $n$  ska varieras.

Att dubbla värdet passar bra om man har (tror sig ha) polynomial komplexitet:

- För en  $\Theta(n)$ -algoritm så bör tiden dubblas om  $n$  dubblas.

- För en  $\Theta(n^2)$ -algoritm så gäller  $\frac{t(2n)}{t(n)} = \frac{c \cdot (2n)^2}{c \cdot n^2} = 4$

- För en  $\Theta(n^3)$ -algoritm så gäller  $\frac{t(2n)}{t(n)} = \frac{c \cdot (2n)^3}{c \cdot n^3} = 8$

# Exempel

- För en  $\Theta(\log n)$ -algorithm så är det bra att kvadrera:  $\frac{\log n^2}{\log n} = 2$

- För en  $\Theta(n \log n)$ -algorithm är en dubblering användbar:

$$\frac{t(2n)}{t(n)} = \frac{c \cdot 2n \log 2n}{c \cdot n \log n} = 2 \cdot \frac{\log 2 + \log n}{\log n} = 2 + \frac{1}{\log n} \approx 2 \text{ för stora } n.$$

- För en exponentiell komplexitet, dvs  $\Theta(a^n)$  så passar  $n$  och  $n + 1$ :

$$\frac{c \cdot a^{n+1}}{c \cdot a^n} = a$$



# Behöver vi bry oss?

Ja! Det finns fortfarande många problem där datorkraften begränsar oss.

Ett axplock:

- fysik och teknik: aerodynamik, väderprognoser, ...
- biologi: bioinfomatik, genomsekvensering, ...
- realtidssystem: robotar, självkörande bilar, ...
- animation: datorspel, filmindustri, ...
- informationssökning: google, ...

Citat från "*The elements of programming style*" av Kernighan och Ritchie:

- Correctness is much more important than speed!
- Do not sacrifice clarity for small efficiency gains!
- Do not sacrifice simplicity for small efficiency gains!
- Do not sacrifice modifiability for small efficiency gains!
- If the program is too slow: Find a better algorithm!

# Några nya Python-detalyer

Man kan deklarera funktioner inuti funktioner.

Första exemplet:

```
def power(x, n):  
    def sqr(x):  
        return x*x  
  
    if n<0:  
        return 1./power(x, -n)  
    elif n==0:  
        return 1  
    elif n%2==0:  
        return sqr(power(x, n//2))  
    else:  
        return x*sqr(power(x, (n-1)//2))
```

# Nya Python-detalljer

Andra exemplet:

```
def fib(n):  
    memory = {0:0, 1:1}  
  
    def _fib(n):  
        if n not in memory:  
            memory[n] = _fib(n-1) + _fib(n-2)  
        return memory[n]  
  
    return _fib(n)
```

# Nya Python-detalyer

Funktioner är *objekt* som kan lagras i variabler, listor, lexikon, ...

```
sort_functions = [ins_sort_iter, merge_sort, psort, sorted]

for sort in sort_functions[1:]:
    print(f'\n ***{sort.__name__}***')
    for n in [100000, 200000, 400000, 800000]:
        lst = []
        for i in range(n):
            lst.append(random.random())
        tstart = time.perf_counter()
        lst = sort(lst)
        tstop = time.perf_counter()
        print(f" Time for {n}\t : {tstop - tstart:4.2f}")
```



UPPSALA  
UNIVERSITET

*The end*

